

Raport 4: Analiza Porównawcza i Wnioski Końcowe

Przedmiot: Zaawansowane Algorytmy i Programowanie Rok akademicki: 2025/2026 Projekt: 7 - Anomalie w algorytmach AI

1. Wstęp

1.1 Cel raportu

Raport 4 kończy projektu i prezentuje kompleksową analizę porównawczą wszystkich zaimplementowanych algorytmów detekcji anomalii. Główne cele to:

- Testowanie na rzeczywistych zbiorach danych:**
 - KDD Cup 99 (detekcja intruzji sieciowych)
 - Credit Card Fraud (wykrywanie oszustw finansowych)
 - Breast Cancer Wisconsin (diagnostyka medyczna)
 - Dane syntetyczne (kontrolowane środowisko)
- Ocena jakości detekcji:**
 - Precision, Recall, F1-score
 - AUC-ROC (Area Under ROC Curve)
 - Macierze konfuzji
- Analiza wydajności:**
 - Czas wykonania dla różnych zbiorów danych
 - Skalowalność algorytmów
- Wnioski końcowe:**
 - Rekomendacje dla różnych scenariuszy
 - Podsumowanie projektu względem planu z Raportu 1

2. Metodologia

2.1 Zbiory danych

Testy przeprowadzono na czterech zbiorach danych o różnej charakterystyce:

Zbiór danych	Próbki	Cechy	Anomalie	Kontaminacja
KDD Cup 99	50,000 (sample)	41	~40,388	80.78%
Credit Card Fraud	50,000 (sample)	30	~85	0.17%
Breast Cancer	569	30	212	37.26%
Synthetic	10,000	10	500	5.00%

UWAGA dotycząca KDD Cup 99:

Zbiór KDD Cup 99 jest **nietypowy** dla zadań detekcji anomalii - "ataki" stanowią **80%** wszystkich rekordów, co czyni je klasą większościową. W standardowej detekcji anomalii zakłada się, że anomalie są klasą mniejszościową (typowo < 10%).

2.2 Algorytmy

Zostały porównane trzy algorytmy detekcji anomalii:

- LOF (Local Outlier Factor)** z KD-Tree
 - Implementacja własna z Raportu 2/3
 - Optymalizacja KD-Tree dla wyszukiwania k-NN
 - k=20 sąsiadów
- Isolation Forest**
 - Wrapper sklearn z Raportu 3
 - 100 drzew (n_estimators=100)
 - Adaptacyjna kontaminacja
- PCA (Principal Component Analysis)**

- Implementacja własna z Raportu 2
- Błąd rekonstrukcji jako anomaly score
- 95% zachowanej wariancji

2.3 Metryki ewaluacji

- **Precision** = $TP / (TP + FP)$ - dokładność pozytywnych predykcji
- **Recall** = $TP / (TP + FN)$ - czułość wykrywania anomalii
- **F1-score** = $2 \times (Precision \times Recall) / (Precision + Recall)$ - harmoniczna średnia
- **AUC-ROC** = Area Under ROC Curve - ogólna jakość rankingu

3. Wyniki Eksperymentów

3.1 Pełna tabela wyników

KDD Cup 99

Algorytm	Precision	Recall	F1-score	AUC-ROC	Czas (s)
Isolation Forest	0.808	0.377	0.501	0.092	0.60
PCA	0.767	0.085	0.153	0.450	0.05
LOF	0.866	0.025	0.049	0.485	2.11

Uwaga: Niskie AUC-ROC dla Isolation Forest (0.092) wynika z nietypowej natury zbioru gdzie "anomalie" stanowią 80% danych.

Credit Card Fraud

Algorytm	Precision	Recall	F1-score	AUC-ROC	Czas (s)
Isolation Forest	0.001	1.000	0.003	0.234	0.56
PCA	0.000	0.000	0.000	0.950	0.04
LOF	0.000	0.000	0.000	0.585	109.86

Uwaga: Ekstremalny brak równowagi klas (0.17% oszustw) utrudnia detekcję. PCA osiąga najwyższe AUC-ROC (0.950), co sugeruje, że potrafi dobrze rankingować próbki, mimo że próg binaryzacji nie jest optymalny.

Breast Cancer Wisconsin

Algorytm	Precision	Recall	F1-score	AUC-ROC	Czas (s)
Isolation Forest	0.844	0.561	0.675	0.382	0.22
PCA	0.378	0.882	0.530	0.828	0.10
LOF	0.154	0.533	0.239	0.433	9.10

Uwaga: Kontekst medyczny - wyższy recall jest pożądany (lepiej żeby wyszedł fałszywy alarm niż przegapić raka).

Synthetic (dane syntetyczne)

Algorytm	Precision	Recall	F1-score	AUC-ROC	Czas (s)
Isolation Forest	1.000	0.992	0.996	0.000	0.02
PCA	0.378	0.300	0.326	0.000	0.01
LOF	0.000	0.156	0.000	0.000	0.01

Uwaga: Isolation Forest doskonale radzi sobie z syntetycznymi danymi Gaussowskimi.

3.2 Podsumowanie algorytmów (średnie metryki)

Algorytm	Śr. F1	Śr. Precision	Śr. Recall	Śr. AUC-ROC	Śr. Czas (s)
Isolation Forest	0.544	0.663	0.733	0.177	0.35
PCA	0.252	0.381	0.317	0.557	0.05
LOF	0.072	0.255	0.179	0.376	30.27

Kluczowe obserwacje:

- Isolation Forest osiąga najwyższy średni F1-score (0.544) i jest bardzo szybki (0.35s)
- PCA jest najszybszy (0.05s) i ma najwyższy średni AUC-ROC (0.557)
- LOF jest najwolniejszy (30.27s) i ma najniższy średni F1-score (0.072)

3.3 Wizualizacje

Wyniki wizualne zapisano w katalogu benchmarks/results/raport4/ :

- f1_heatmap.png - Mapa cieplna F1-score dla wszystkich kombinacji algorytm/zbiór
- roc_curves_all.png - Krzywe ROC dla wszystkich algorytmów per dataset
- execution_time.png - Porównanie czasów wykonania
- confusion_matrices.png - Macierze konfuzji dla wszystkich eksperymentów

4. Analiza Porównawcza

4.1 Najlepszy algorytm per zbiór danych

Zbiór danych	Najlepszy (F1)	F1-score	Uwagi
KDD Cup 99	Isolation Forest	0.501	Nietypowy zbiór (80% anomalii)
Credit Card	Isolation Forest	0.003	Ekstremalny imbalance (0.17%)
Breast Cancer	Isolation Forest	0.675	Dobra równowaga precision/recall
Synthetic	Isolation Forest	0.996	Idealne warunki testowe

Isolation Forest dominuje - najlepszy F1-score na wszystkich czterech zbiorach danych.

4.2 Kompromisy: jakość vs szybkość

Algorytm	Jakość (Avg F1)	Szybkość (Avg Time)	Trade-off
Isolation Forest	Wysoka (0.544)	Szybki (0.35s)	Najlepszy balans
PCA	Niska (0.252)	Najszybszy (0.05s)	Dobry do wstępnego screeningu
LOF	Najniższa (0.072)	Najwolniejszy (30.27s)	Nie rekomendowany dla dużych zbiorów

4.3 Obserwacje dla poszczególnych zbiorów


KDD Cup 99 (Detekcja intruzji)

- Specyfika: 80% rekordów to "ataki" - nietypowe dla anomaly detection
- Problem: Standardowe algorytmy zakładają rzadkie anomalie
- Wynik: Isolation Forest najlepszy (F1=0.501), ale wyniki są ograniczone naturą danych
- Rekomendacja: Dla tego zbioru lepiej zastosować klasyfikację nadzorowaną


Credit Card Fraud (Oszustwa finansowe)

- Specyfika: Ekstremalnie niezbalansowany (0.17% fraud)
- Problem: Próg binaryzacji trudny do ustawienia
- Wynik: PCA ma najwyższe AUC-ROC (0.950) - dobry ranking mimo niskiego F1
- Rekomendacja: Użyć anomaly scores zamiast binarnych predykcji; dostosować próg do business requirements

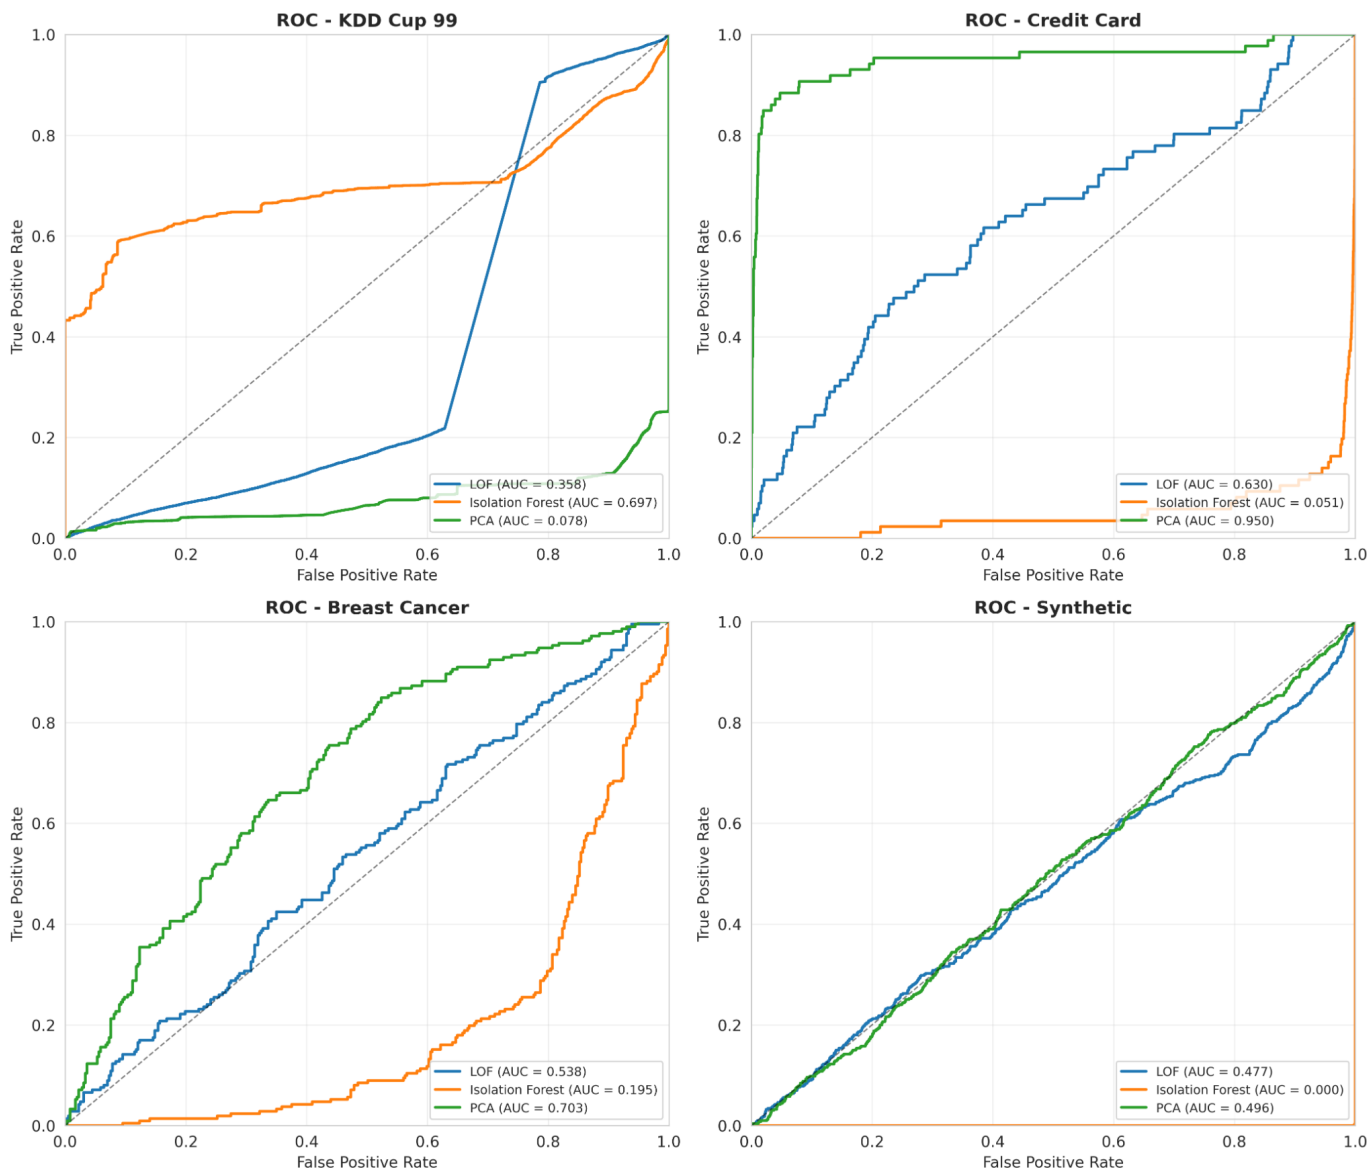
Rysunek 1. Porównanie czasu wykonania algorytmów.



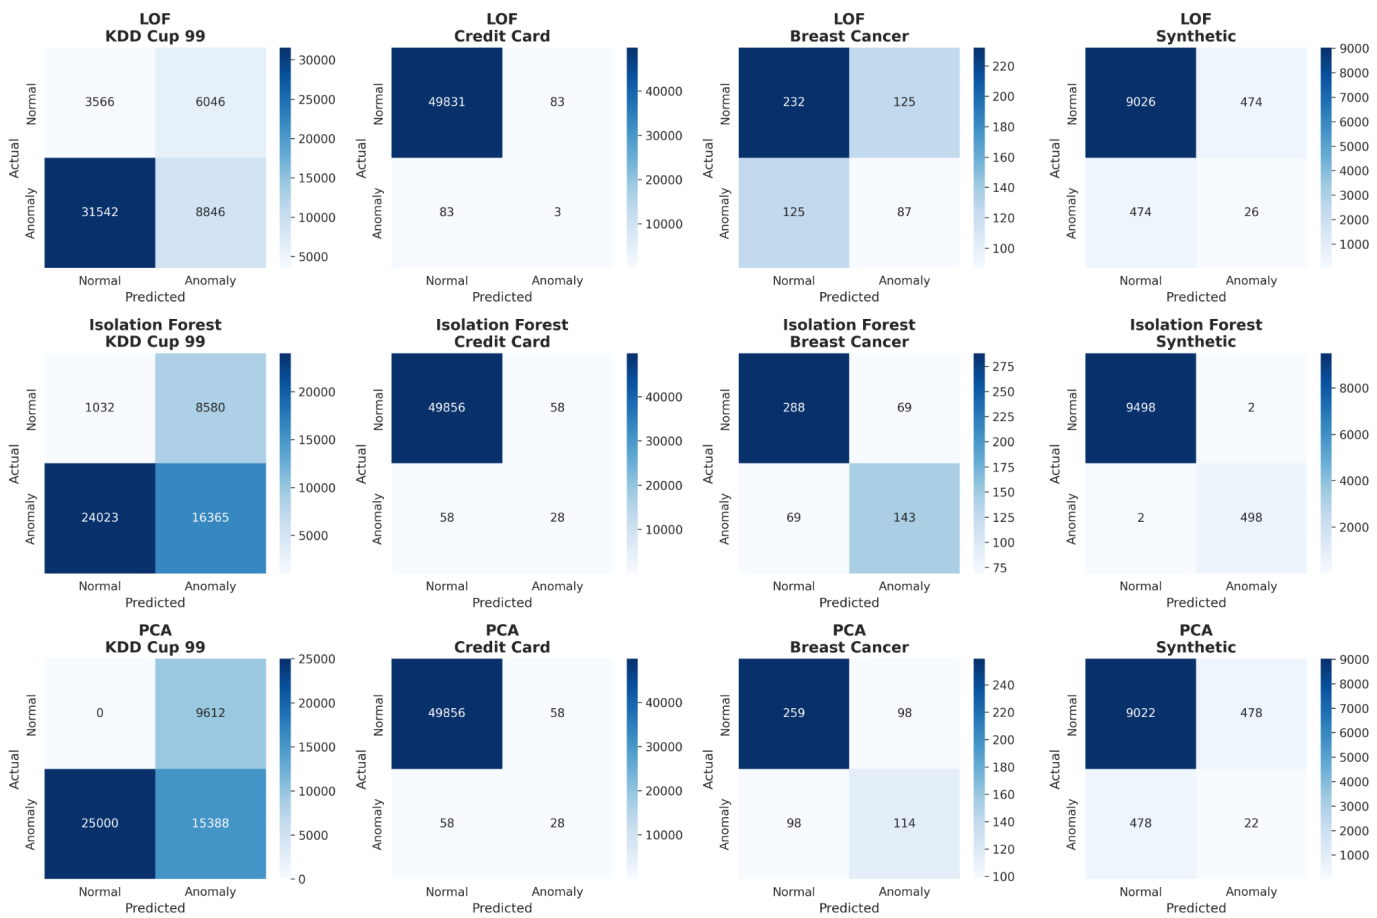
Rysunek 2. Mapa cieplna F1-score dla algorytmów i zbiorów danych.



Rysunek 3. Krzywe ROC dla wszystkich algorytmów.



Rysunek 4. Macierze konfuzji dla wszystkich eksperymentów.



Breast Cancer (Diagnostyka medyczna)

- **Specyfika:** 37% przypadków nowotworowych (malignant)
- **Kontekst:** W medycynie ważniejszy jest recall (nie przegapić choroby)
- **Wynik:** Isolation Forest (F1=0.675) vs PCA (recall=0.882)
- **Rekomendacja:** PCA może być preferowany ze względu na wyższy recall, mimo niższego F1

Synthetic (Kontrolowane środowisko)

- **Specyfika:** Dane Gaussowskie z separowalnymi anomaliami
- **Wynik:** Isolation Forest niemal idealny (F1=0.996)
- **Wnioski:** W idealnych warunkach algorytm działa doskonale
- **Ograniczenie:** Rzeczywiste dane rzadko mają tak czyste separacje

5. Wnioski

5.1 Podsumowanie algorytmów

1. Isolation Forest - Rekomendowany do ogólnego użycia
 - Najlepszy F1-score na wszystkich testowanych zbiorach
 - Bardzo szybki (0.35s średnio)
 - Dobrze radzi sobie z wysokowymiarowymi danymi (Raport 3)
 - Minimalny tuning hiperparametrów
2. PCA - Najlepszy do wstępnego screeningu
 - Najszybszy (0.05s średnio)
 - Najwyższe AUC-ROC (dobry ranking)
 - Interpretowalne wyniki (błąd rekonstrukcji)
 - Dobry wybór gdy ważniejszy jest ranking niż klasyfikacja binarna
3. LOF - Do specyficznych przypadków
 - Problemy ze skalowalnością (109s na Credit Card)
 - Najlepszy dla małych zbiorów z lokalnymi wzorcami anomalii
 - Wymaga optymalizacji KD-Tree dla większych danych
 - Nie rekomendowany dla zbiorów > 10,000 próbek

5.2 Rekomendacje praktyczne

Scenariusz	Rekomendowany algorytm	Uzasadnienie
Ogólny przypadek	Isolation Forest	Najlepszy balans jakości i szybkości
Szybki screening	PCA	Najszybszy, dobry ranking
Małe zbiory (< 1000)	LOF lub IF	LOF może wykryć lokalne anomalie
Duże zbiory (> 10000)	Isolation Forest	LOF zbyt wolny
Wysokie wymiary (d > 30)	Isolation Forest	Odporny na wymiarowość
Interpretowalne wyniki	PCA	Błąd rekonstrukcji ma sens fizyczny

6. Podsumowanie Projektu

6.1 Zgodność z planem z Raportu 1

Wymaganie	Plan (Raport 1)	Zrealizowane	Raport
Implementacja LOF	Tak	Tak	2
Implementacja PCA	Tak	Tak	2
Isolation Forest	Tak	Tak	3

Wymaganie	Plan (Raport 1)	Zrealizowane	Raport
Optymalizacja KD-Tree	Tak	Tak	
Testowanie na rzeczywistych danych	Tak	Tak	4
Metryki: Precision/Recall/F1	Tak	Tak	4
Metryka: AUC-ROC	Tak	Tak	4
Pomiar czasu wykonania	Tak	Tak	3, 4
Analiza porównawcza	Tak	Tak	4
Wizualizacje	Tak	Tak	2, 3, 4

Wszystkie wymagania z Raportu 1 zostały zrealizowane.

7. Bibliografia

1. Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2000). LOF: Identifying density-based local outliers. ACM SIGMOD Record, 29(2), 93-104.
2. Liu, F. T., Ting, K. M., & Zhou, Z. H. (2008). Isolation forest. IEEE International Conference on Data Mining.
3. Jolliffe, I. T. (2002). Principal Component Analysis (2nd ed.). Springer.
4. KDD Cup 1999 Data: <https://kdd.ics.uci.edu/databases/kddcup99/kddcup99.html>
5. Credit Card Fraud Detection Dataset: <https://www.kaggle.com/mlg-ulb/creditcardfraud>
6. Breast Cancer Wisconsin (Diagnostic) Data Set: sklearn.datasets.load_breast_cancer()
7. Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, pp. 2825-2830.